




## 제7장 불확실성

# 학습 목표

- 불확실성의 개념과 기본 확률 이론을 이해한다.
- 베이즈 추론을 이해한다.
- 전문가 시스템에서 사용되는 확신도 시스템을 이해한다.

# 01 불확실성

- 고전적인 논리를 이용하여 추론을 하려면 규칙의 전체 조건이나 결론이 항상 참이거나 거짓이어야 한다. 즉 100% 확실하여야 한다.
  - IF            A is true
  - THEN       B is true
- 현실 세계에서 100% 확실한 정보나 지식을 얻는다는 것은 상당히 힘들다. 따라서 우리가 사용하는 정보나 지식은 항상 어느 정도 불확실하다고 할 수 있다.

# 불확실성의 예

- 집에서 공항까지 가서 탑승하는 문제
  - 중간에 자동차가 고장 날 수도 있고,
  - 엄청난 차량 정체를 겪을 수도 있다.
  - 공항이 몹시 혼잡하여서 수속에 시간이 많이 걸릴 수도 있다.





그림 7-1 불확실성이 발생하는 문제

# 불확실성의 예

- 내과에서 환자를 진단하는 전문가 시스템
  - 규칙: 감기이다 → 열이 있다. -> 100% 확실할 수 없다.



# 불확실성은 왜 발생하는 것인가?

- 데이터의 불확실성: 센서로부터 얻는 데이터는 장치의 측정 오류나 오차 때문에 완전하지 못하다.
- 지식의 불완전성: 전문가로부터 얻는 지식은 완전하지 않을 수 있다. 문제 영역 자체가 불확실할 수도 있다. 예를 들어서 주식 예측이나 부동산 투자의 경우에는 문제 자체에 불확실성이 존재한다.
- 전문가들의 관점이 다른 경우: 전문가들마다 의견이 다를 수 있다.
- 정보 획득의 불완전성: 정보 자체를 모두 수집하거나 처리할 수 없기 때문에 불확실성이 발생한다. 예: 자율주행의 환경 정보
- 부정확한 언어: 인간이 사용하는 자연어에는 모호한 단어가 많다.

# 인공지능 시스템에서의 불확실성 처리

- 불확실한 지식이나 정보를 가지고도 올바른 결정을 내릴 수 있어야 한다.
  - 인공지능 시스템에서는 참과 거짓이 아니라 믿음의 정도(degree of belief)를 제공
- 믿음의 정도(또는 가능성)를 다루는 수학적 도구는 확률 이론(probability theory)이다.
- 불확실성을 처리하는 대표적인 2가지 방법
  - 베이즈 추론(Bayesian reasoning)
  - 확신도(certainty factor)

## 02 확률을 이용한 불확실성 처리

- 확률적인 추론(probabilistic reasoning)에서는 명제의 진리값이 0(거짓) 또는 1(참)이 아니고 0.0에서 1.0 사이의 값을 가진다.
  - 확률적인 추론에서는 가장 확률이 높은 결론이 선택된다.
- 주사위 한번 던지기 실험에서 1과 3이 나오는 사건은 상호 배타적인 사건
  - 동시에 일어날 수 없는 사건, 둘 중 하나만 발생할 수 있는 사건. 독립적이지 않음
  - 한 사건이 발생하면 다른 사건은 반드시 발생하지 않으며, 두 사건의 교집합이 **빈 집합**:  $P(A \cap B) = 0$ 
    - 주사위 한번 던질 때 **짝수**가 나오는 사건과 **홀수**가 나오는 사건은 상호 배타적
  - **조건부 확률은 상호 배타적이지 않은 경우: 교집합이 0이 아닌 경우**
- 상호 독립적
  - A가 일어난 일이 B가 일어나는 확률에 영향을 주지 않는 경우
    - 주사위 던지기와 동전 던지기는 상호 독립적, 주사위 두 번 던지기도 독립적
  - 조건부 확률을 적용할 수 있지만, 원래 확률과 같음
  - $P(A|B) = P(A)$ ,  $P(A \cap B) = P(A) \times P(B)$





# 조건부 확률

- $p(A|B)$ 
  - 사건 B가 발생했을 때, 사건 A가 발생할 확률
- $p(A \cap B)$ 
  - A와 B의 결합 확률
  - A와 B가 동시에 발생할 확률

# 사전 확률과 사후 확률

$$p(A|B) = \frac{A \text{와 } B \text{가 동시에 발생할 경우의 수}}{B \text{가 발생할 경우의 수}}$$

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

$$p(B|A) = \frac{p(A \cap B)}{p(A)}$$

$$p(A \cap B) = p(B|A) \times p(A)$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

# 베이지 규칙 (Bayes Rule)

The diagram shows the Bayes' Rule formula with four red arrows pointing to its components:

- An arrow from the top label "사전확률 (prior)" points to  $p(A)$  in the numerator.
- An arrow from the top-left label "가능도 (likelihood)" points to  $p(B|A)$  in the numerator.
- An arrow from the bottom-right label "사전확률 (evidence)" points to  $p(B)$  in the denominator.
- An arrow from the bottom-left label "사후확률 (posterior)" points to  $p(A|B)$  on the left side of the equation.

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

- 베이지 정리
  - 계산하기 쉬운 사후 확률(가능도)을 이용하여서 계산하기 어려운 사후 확률을 계산하는 방법
  - $p(A|B)$ 를 직접 계산하기는 힘들 경우에는, 상대적으로 계산하기 쉬운  $p(B|A)$ ,  $p(A)$ ,  $p(B)$ 를 이용하여 계산하는 방법

# 베이즈 정리

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

$$p(B) = p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)$$



$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

# Confusion Matrix

|              |          | Predicted Class                            |                                                          |                                                        |
|--------------|----------|--------------------------------------------|----------------------------------------------------------|--------------------------------------------------------|
|              |          | Positive                                   | Negative                                                 |                                                        |
| Actual Class | Positive | True Positive (TP)                         | False Negative (FN)<br><b>Type II Error</b>              | <b>Sensitivity</b><br>$\frac{TP}{TP + FN}$ recall      |
|              | Negative | False Positive (FP)<br><b>Type I Error</b> | True Negative (TN)                                       | <b>Specificity</b><br>$\frac{TN}{TN + FP}$             |
|              |          | <b>Precision</b><br>$\frac{TP}{TP + FP}$   | <b>Negative Predictive Value</b><br>$\frac{TN}{TN + FN}$ | <b>Accuracy</b><br>$\frac{TP + TN}{TP + TN + FP + FN}$ |

- Recall(재현율, 민감도): 얼마나 실제 참이 예측되었는가? 실제 True 중 모델이 True 로 예측한 비율
- Precision(정밀도): 얼마나 예측이 실제 참을 찾아내는가? 모델이 True 라고 한 것 중 실제 True 비율
- Specificity(특이도): 실제 negative 중 negative로 맞게 판정하는 비율

- F1 Score
  - 정밀도(Precision)와 재현율(Recall)의 조화평균(Harmonic Mean)
  - $F1\ Score = 2 * (Precision * Recall) / (Precision + Recall)$
- F1 Score는 다음과 같은 상황에서 특히 유용
  - 데이터 불균형(Imbalanced Data)이 심할 때
    - 예: 스팸 메일 분류 (스팸 1%, 정상 메일 99%). 단순히 '정상 메일'이라고만 예측해도 정확도(Accuracy)는 99%지만, 이는 무의미함. F1 Score는 스팸을 찾아내는 성능을 제대로 평가함
  - False Negative(FN)와 False Positive(FP) 모두 중요할 때
    - 예: 암 진단, 금융 사기 탐지 등. (FN: 환자를 놓침, FP: 건강한 사람을 불안하게 함)
  - 정밀도와 재현율 중 하나만 높은 '치팅' 모델을 걸러낼 때

# Lab: Z-바이러스 1

- 세계의 인구의 10%가 Z-바이러스에 감염되었다.
- Z-바이러스 감염자이면 90% 확률로 positive로 판정한다. 민감도 (Sensitivity). Recall (Type II error 포함)
- Z-바이러스 감염자가 아니면 70%의 확률로 negative로 판정한다. 특이도 (Specificity)
- 어떤 개인이 검사를 하였는데 positive로 나왔다면 이 개인이 좀비일 확률은 얼마나 될까?



|   | P      | N      |
|---|--------|--------|
| P | TP 0.9 | FN 0.1 |
| N | FP 0.3 | TN 0.7 |

# Lab: Z-바이러스 1

$$\begin{aligned}P(\text{Zombie}|+) &= \frac{P(+|\text{Zombie})P(\text{Zombie})}{P(+)} \\&= \frac{P(+|\text{Zombie})P(\text{Zombie})}{P(+|\text{Zombie})P(\text{Zombie}) + P(+|\neg\text{Zombie})P(\neg\text{Zombie})} \\&= \frac{0.90 \times 0.1}{0.90 \times 0.1 + 0.30 \times 0.90} \\&= 0.25\end{aligned}$$

|   | P      | N      |
|---|--------|--------|
| P | TP 0.9 | FN 0.1 |
| N | FP 0.3 | TN 0.7 |



# Lab: Z-바이러스 2

$P(+|D)$ : 감염자에 대해서 시약을 적용해서 positive로 나온 비율이다(95%)

$P(D)$ : 전체 인구 중에서 감염자의 비율이다(1%).

$P(\neg D)$ : 전체 인구 중에서 비감염자의 비율이다(99%).

$P(+|\neg D)$ : 비감염자에 대해서 시약을 적용해서 positive로 나온 비율이다(2%)

$P(D|+)$ : positive로 나왔을 때, 실제 감염자인 확률이다. 우리가 알고 싶은 확률이다.

|   | P       | N       |
|---|---------|---------|
| P | TP 0.95 | FN 0.05 |
| N | FP 0.02 | TN 0.98 |

# Lab: Z-바이러스 2

$$P(+|D): 0.95$$

$$P(D): 0.01$$

$$P(\neg D): 0.99$$

$$P(+|\neg D): 0.02$$

|   | P       | N       |
|---|---------|---------|
| P | TP 0.95 | FN 0.05 |
| N | FP 0.02 | TN 0.98 |

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|\neg D)P(\neg D)} = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.02 \times 0.99} \approx 0.32$$

## Lab: Z-바이러스 2

- 만약 시약이 위양성(false-positive)이 없다면 이 사람은 100% 감염된 것으로 판정된다.

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|\neg D)P(\neg D)} = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.00 \times 0.99} \approx 1.0$$

# Lab: 과일 문제

- 그릇 #1에는 사과 10개와 바나나 30개가 있으며 그릇 #2에는 사과와 바나나가 각각 20개가 있다. 어떤 사람이 그릇을 무작위로 골라 과일을 무작위로 선택한다고 하자. 어떤 사람이 선택한 과일이 바나나로 판명되었다. 그 사람이 그릇 #1에서 바나나를 선택했을 가능성은 얼마나 될까?



사과 10개  
바나나 30개



사과 20개  
바나나 20개

# Lab: 과일 문제

$$\begin{aligned} p(H_1|E) &= \frac{p(E|H_1) \times p(H_1)}{p(E|H_1) \times p(H_1) + p(E|H_2) \times p(H_2)} \\ &= \frac{0.75 \times 0.5}{0.75 \times 0.5 + 0.5 \times 0.5} = 0.6 \end{aligned}$$



사과 10개  
바나나 30개



사과 20개  
바나나 20개

# Q

- 공이 들어 있는 두 개의 항아리가 있다. 첫 번째 항아리에는 빨간 공 50개와 파란 공 50개가 들어 있다. 두 번째 항아리에는 30개의 빨간 공과 70개의 파란 공이 들어 있다. 두 항아리 중 하나가 무작위로 선택되고, 선택된 항아리에서 공을 무작위로 뽑는다. 빨간 공이 뽑혔을 때 첫 번째 항아리에서 선택되었을 확률은 얼마인가? 베이즈 규칙을 사용하여 계산하라.

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

# Lab: 카드 게임

- 우리가 한 장의 카드를 가지고 있는데 카드에 얼굴이 그려져 있다는 것만 알고 있다. 이 상황에서 이 카드가 킹(king)일 확률을 추론해보자. 즉  $P(\text{King} \mid \text{Face})$  확률을 계산해보는 것이다.



# Lab: 카드 게임

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)}$$

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)} = \frac{13}{3} \frac{1}{13} = \frac{1}{3}$$





## 03 베이지 정리와 추론

- 전문가 시스템의 규칙
  - IF  $E$  is true
  - THEN  $H$  is true (확률:  $p$ )
- (예)  $p(H|E)$ 
  - IF 기침을 한다.
  - THEN 감기이다. (확률: 0.7)
- 규칙의 확률 계산은 어떻게?
  - 통계 자료(사전확률, 가능성도, ...)가 제공되어야 베이지 정리로 확률 계산 가능


# 베이즈 정리와 추론

$$p(H|E) = \frac{p(E|H) \times p(H)}{p(E|H) \times p(H) + p(E|\neg H) \times p(\neg H)}$$

- $P(H)$  - 가설  $H$ 가 참일 확률(사전 확률)
- $P(\neg H)$  - 가설  $H$ 가 거짓일 확률(사전 확률)
- $p(E|H)$  - 가설  $H$ 가 참일 때, 증거  $E$ 가 나타날 확률(가능도)
- $p(E|\neg H)$  - 가설  $H$ 가 거짓임에도, 증거  $E$ 가 나타날 확률(가능도)

## 위의 사전 확률과 가능도는 누가 제공해야 하는 것일까?

- 전문가 시스템에서 사용되는 규칙이라면 전문가들이 이들 확률을 제공해야 한다.
- 가설이 나타날 확률  $P(H)$
- 가설이 나타나지 않을 확률  $P(\neg H)$
- 가설이 참일 때 증거가 나타날 확률  $p(E|H)$
- 가설이 거짓일 때, 증거  $E$ 가 나타날 확률  $p(E|\neg H)$
- 의사와 같은 전문가라면 제공할 수 있는가?



## 증거와 가설이 여러 개일 때

(예) 가설이 상호 배타적(동시에 일어나지 않는 사건)이어야 계산 가능

- IF 기침을 한다.(E)
- THEN 감기이다. (H1)
  
- IF 기침을 한다. (E)
- THEN 폐렴이다. (H2)

$$p(H_i|E) = \frac{p(E|H_i) \times p(H_i)}{\sum_{k=1}^m p(E|H_k) \times p(H_k)}$$

# 베이즈 정리의 단점

- 베이즈 추론이 정확한 결과를 도출하려면 사전 확률과 같은 확률값이 입력되어야 한다.
- 어떤 분야에서는 믿을만한 통계 자료가 없어서 사전 확률을 산정할 수 없는 경우도 있다. 예를 들어서 의학 분야에서는 이러한 자료를 얻기가 상당히 힘들다.

# Lab: 베이지 정리로 규칙의 확률 계산

- 규칙

IF        치통이 있다.  
THEN    충치이다. (확률: ???)

|           | 치통   | $\neg$ 치통 |
|-----------|------|-----------|
| 충치        | 0.04 | 0.06      |
| $\neg$ 충치 | 0.01 | 0.89      |

Confusion Matrix 아님


## Lab:베이지 정리로 규칙의 확률 계산 실습

$$P(\text{충치} | \text{치통}) = \frac{P(\text{충치} \wedge \text{치통})}{P(\text{치통})} = \frac{0.04}{(0.04 + 0.01)} = 0.8$$

$$P(\neg \text{충치} | \text{치통}) = \frac{P(\neg \text{충치} \wedge \text{치통})}{P(\text{치통})} = \frac{0.01}{(0.04 + 0.01)} = 0.2$$


IF        치통이 있다.  
THEN    충치이다. (확률: 0.8)

|     | 치통   | ¬치통  |
|-----|------|------|
| 충치  | 0.04 | 0.06 |
| ¬충치 | 0.01 | 0.89 |



# Lab:스팸 필터링

- 조건부 확률 계산  $P(\text{spam}|\text{word})$
- 전체 메일 중에 40%가 스팸 메일이다.
- 스팸 메일 중의 1%가 제목으로 특정한 word를 가진다.
- 정상 메일 중의 0.4%가 제목으로 특정한 word를 가진다.
- 메일의 제목에 특정 word가 있을 때 스팸일 확률은?





# Lab:스팸 필터링

$$P(spam|word) = \frac{P(word|spam) \times P(spam)}{P(word|spam) \times P(spam) + P(word|\neg spam) \times P(\neg spam)}$$

- 여기서  $P(spam) = 0.4$  이고  $P(word|spam) = 0.01$ 이다. 또  $P(word|\neg spam)$ 은 0.004,  $P(\neg spam)$ 은 0.6이다. 따라서 다음과 같은 결과를 얻는다.

$$P(spam | word) = 0.004/(0.0064)=5/8=0.625$$


# Q

- 어떤 컨설팅 회사가 경기 침체를 예측하는 수학적 모델을 만들었다. 모델은 경기 침체가 실제로 발생할 때 80%의 확률로 경기 침체를 예측하고, 경기 침체가 없을 때 10%의 확률로 경기 침체를 예측한다. 경기 침체에 빠질 사전 확률은 20%이다. 이 모델이 경기 침체를 예측한다면 경기 침체가 실제로 일어날 확률은 얼마인가? 베이즈 규칙을 사용해서 계산하라.

|   | P      | N      |
|---|--------|--------|
| P | TP 0.8 | FN 0.2 |
| N | FP 0.1 | TN 0.9 |


# Lab: 몬티홀 문제

- 세계적인 공학자 5000명을 혼란에 빠뜨린 유명한 확률 문제가 있다. 바로 몬티 홀 문제(Monty Hall problem)이다.
- 사용자가 맞추면 상품을 주는 퀴즈쇼(Let's Make a Deal)가 있다. 이 게임쇼에서는 세 개의 문 중에서 하나를 선택할 수 있다. 하나의 문 뒤에는 자동차가 있고 다른 문들 뒤에는 염소가 있다.




# Lab: 몬티홀 문제

- 사용자가 1번 문을 선택하면 그 문 뒤에 무엇이 있는지 아는 사회자 (Monty Hall)가 염소가 있는 문(3번문이라고 하자.)을 연다. 그런 다음, 사회자는 당신에게 선택을 바꿀 기회를 준다.
- 선택을 바꾸는 것이 사용자에게 유리할까? 그대로 있는 것이 유리할까?



# Lab: 몬티홀 문제

- 직관적인 설명: 일단 참가자가 1 번 문을 선택하였고 자동차가 각 문 뒤에 있었을 3가지의 경우를 생각할 수 있다.




# Lab: 몬티홀 문제

- 베이즈 정리를 이용해보자.

$$P(\text{문2에 자동차} | \text{사회자 문3 열음}) = \frac{P(\text{사회자 문3 열음} | \text{문2에 자동차}) P(\text{문2에 자동차})}{P(\text{사회자 문3 열음})}$$

$$P(\text{문2에 자동차} | \text{사회자 문3 열음}) = \frac{1 * (1/3)}{(1/2)} = \frac{2}{3}$$



# Lab: 몬티홀 문제

```
import random

NGames=10000
UnchangeGame=[]
ChangeGame=[]

for i in range(0, NGames):

    # 자동차는 랜덤하게 숨겨진다.
    CarDoor=random.choice(["Door1", "Door2", "Door3"])
    # 사용자가 첫 번째 선택을 한다.
    UserDoor=random.choice(["Door1", "Door2", "Door3"])
    # 호스트가 자동차가 있지 않은 문을 연다.
    OpenDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, CarDoor]))[0]
    # 남아 있는 문을 결정한다.
    OtherDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, OpenDoor]))[0]

    # 사용자가 선택을 바꾸지 않아서 성공하면 True를 리스트에 추가한다. True는 정수 1이다.
    UnchangeGame.append(UserDoor==CarDoor)
    # 사용자가 선택을 바꾸어서 성공하면 True를 리스트에 추가한다. True는 정수 1이다.
    ChangeGame.append(OtherDoor==CarDoor)

# 각 리스트에서 정수 1의 개수를 센다.
print(f"{NGames} 개의 게임 중에서 바꾸지 않았을 때의 승률: {sum(UnchangeGame)/NGames} \n\
      바꾸었을 때의 승률: {sum(ChangeGame)/NGames}")
```

# Lab: 몬티홀 문제


10000 개의 게임 중에서 바꾸지 않았을 때의 승률: 0.3313

바꾸었을 때의 승률: 0.6687



## 04 확신도

- 베イズ 추론의 대안으로 가장 잘 알려져 있는 것은 확신도(certainty factor)이다.
- 확신도는 MYCIN이라는 전문가 시스템에서 사용됨
- MYCIN은 박테리아 감염을 진단하고 치료하는 전문가 시스템
- 확률 이론을 사용하기 위해서는 너무 많은 조건부 확률이 필요



# 확신도

- 확신도는 전문가들의 신뢰도를 나타내는 수치이다.
- 확신도는 -1.0에서 +1.0까지 줄 수 있다.
  - -1.0값은 확실한 거짓이라는 것을 의미하고 +1.0 값은 확실한 참을 의미한다.

|      |                  |
|------|------------------|
| IF   | E (증거)           |
| THEN | H (가설, cf: +0.8) |

|      |                                                                                                                                                                |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| IF   | 1) The stain of the organism is gram positive, and<br>2) The morphology of the organism is coccus, and<br>3) The growth conformation of the organism is chains |
| THEN | There is suggestive <b>evidence (0.7)</b> that the<br>identity of the organism is streptococcus                                                                |

# 확신도의 계산

- $cf[H, E] = MB(H, E) - MD(H, E)$ 
  - $cf[H, E]$ 는 증거  $E$ 를 가지고 있을 때, 가설  $H$ 에 대한 확신도이다.
  - $MB[H, E]$ 는  $E$ 가  $H$ 를 지지하는 정도를 측정한다.
    - Measure of Belief
  - $MD[H, E]$ 는  $E$ 가  $H$ 의 부정을 지지하는 정도를 측정한다.
    - Measure of Disbelief
- MYCIN에서  $MB$ 와  $MD$ 는 전문가인 의사들이 배정하는 확률로 정의된다. 따라서 이들은 모두 0에서 1 사이의 값을 가진다. 따라서  $cf$ 는 -1과 1 사이의 값을 가진다.  $cf$ 가 1을 향함에 따라 증거는 점점 가설을 지지한다.

# 확신도의 계산

- MYCIN에서는 어떤 규칙이 점화되기 위해서는 확신도가 문턱값을 넘어야 한다. 이때 불신의 정도인 MD가 영향을 심하게 끼치게 된다.
- 예를 들어서 어떤 규칙의 MB = 0.8 이고 MD = 0.6이라고 하자. 이 규칙이 점화되기 위한 확신도의 문턱값은 0.25라고 하자. 이 규칙은 MB가 0.8이나 되지만 점화될 수가 없다. MD도 상당히 높기 때문이다.
- 이 단점을 방지하기 위하여 확신도의 정의를 다음과 같이 변경한다.
  - $cf[H, E] = (MB - MD) / (1 - \min(MB, MD))$
  - $(0.8 - 0.6) / (1 - \min(0.8, 0.6)) = 0.2 / 0.4 = 0.5$

# 불확실한 증거를 가진 규칙에서의 확신도

- 불확실한 증거를 가진 규칙에서의 확신도
  - IF            E (불확실한 증거)
  - THEN        H (가설)
- $cf(H, e) = cf(E, e) \times cf(H, E)$
- (예)
  - IF            하늘이 흐리다.(불확실한 증거)
  - THEN        비가 온다.(가설,  $cf=0.8$ )
  - $cf(E, e)$ : 불확실한 증거 e에 의한 증거 E의 확신도
  - 규칙의 전제인 "하늘이 흐리다"의 확신도가 0.6
  - $cf(H, e) = cf(E, e) \times cf(H, E) = 0.6 \times 0.8 = 0.48$

# 규칙이 여러 개의 전제를 가지는 경우

- AND로 연결되는 경우
  - IF            E1 AND E2
  - THEN        H (가설, cf)
  - $cf(H, E1 \cap E2) = \min( cf(E1), cf(E2) ) \times cf(H, E)$
- OR로 연결되는 경우
  - IF            E1 OR E2
  - THEN        H (가설, cf)
  - $cf(H, E1 \cup E2) = \max( cf(E1), cf(E2) ) \times cf(H, E)$

# 규칙이 여러 개의 전제를 가지는 경우

- 규칙
  - IF            하늘이 흐리다. OR 비가 온다.
  - THEN       우산을 준비한다.(cf 0.9)
- “하늘이 흐리다”의 확신도는 0.5, “비가 온다”의 확신도는 0.6
- “우산을 준비한다”는 가설의 확신도는 다음과 같이 계산할 수 있다.
  - $cf(H, E1 \cup E2) = \max(0.5, 0.6) \times 0.9 = 0.54$

# Lab: 확신도 계산

- 확신도를 가지고 여러 가지 계산을 해보자. 만약 다음과 같이 규칙의 증거가 여러 증거들의 조합이라고 할 때, 규칙의 확신도는 어떻게 계산해야 하는가?

```
IF (E1 AND E2 AND E3) OR (E4 AND NOT E5)  
THEN H
```

- 구체적인 수를 가지고 계산해보자.  $E1 = 0.8$ ,  $E2 = 0.9$ ,  $E3 = 0.1$ ,  $E4 = -0.4$ ,  $E5 = -0.5$ 라고 하면 전체 증거의 확신도는 다음과 같다.

$$\begin{aligned} E &= \max(\min(0.8, 0.9, 0.1), \min(-0.4, -(-0.5))) \\ &= \max(0.1, -0.4) \\ &= 0.1 \end{aligned}$$



# Summary

- 확률 이론은 전문가 시스템에서 불확실성을 다룰 수 있도록 수학적으로 정확한 접근법을 알려준다. 베이즈 추론이 대표적인 예이다.
- 베이즈 추론이란 "IF 증거 THEN 가설"에서 증거의 확률이 주어지는 경우에 가설의 신뢰도를 조건부 확률로 계산하는 방법이다.
- 확신도 이론은 베이즈 추론의 대안으로 많이 사용된다. 박테리아 감염을 진단하는 MYCIN에서 사용하였다. 확신도 이론이란 "IF 증거 THEN 가설"에서 증거의 확신도가 주어지는 경우에 가설의 신뢰도를 확신도 형태로 계산하는 방법이다.

# Q & A

